

Pré-requisito para a Ciência Aberta

#### **Paulo Meirelles**

Centro de Matemática, Computação e Cognição Universidade Federal do ABC, São Paulo



# **COMPUTAÇÃO°**





#### CIÊNCIA ABERTA - COLABORAÇÃO SEM BARREIRAS PARA O AVANÇO DO CONHECIMENTO

ue é Ciència Aberta? amos separar a 'espeificação' da 'implemenação". Embora não haja ıma definição fixa para termo "Ciência Aberta", ele costuma ser usado para denotar o conjunto de políticas, iniciativas e ações e desenvolvimento em Computação.

Ciência Aberta - introdução e implemen- para disseminar e compartilhar conhecimento, geralmente por meio digital, para que todos os resultados associados à a todos. O conceito principal desta especificação é colaboração sem barreiras - geográficas, temporais, culturais, sócio-econômicas ou políticas.

A implementação exige pesquisa

COMPUTAÇÃO BRASIL I DEZEMBRO 2021 8



#### **SOFTWARE LIVRE: PRÉ-REQUISITO** PARA A CIÊNCIA ABERTA

Christina von Flach e Fabio Kon flach@ufba.br, kon@ime.usp.br

ciência sempre se pautou pela disseminação do conhecimento, com destague para a mentos. É claro que há limites práticos - e mesmo éticos - para o que pode ser compartilhado e reproduzido, mas expandir esses limites é um objetivo de interesse o foco do movimento pela ciência aberta, que tem tido bastante repercussão nos últimos anos.

A Ciência Aberta requer que as ferramentas e os instrumentos necessários para a prática científica estejam dis-

poníveis para todos, de modo que os experimentos possam ser reproduzidos e os resultados verificados por terceiros. No reprodutibilidade de experi- Século 21, o software consolidou-se como onipresente no conjunto de ferramentas usado por pesquisadores das Ciências Exatas e Biomédicas e tem uso crescente nas Ciências Sociais e Humanas. Software para cientistas de todas as áreas. Esse é é usado para limpeza, processamento e visualização de dados, bem como para criar modelos e realizar previsões. Algoritmos especializados são codificados na forma de bibliotecas, scripts e metadados. Sem compartilhar todos esses artefatos, é muito difícil e custoso reproduzir a pesquisa científica e validar sua correção.



CHRISTINA VON FLACH é Professora Associada do Instituto de Computação da Universidade Federal da Bahia. Atua na área de Engenharia de Software tendo publicado mais de 100 artigos científicos em congressos e periódicos. Recentemente tem trabalhado com temas relacionados à Educação em Engenharia de Software, Sustentabilidade e Aspectos Sóciotécnicos de Ecossistemas de Software, e Ciência Aberta.

**FABIO KON** é Professor Titular de Ciência da Computação na Universidade de São Paulo. Atua na área de Sistemas Distribuídos, Engenharia de Software e Ciência de Dados tendo publicado cerca de 200 artigos científicos em congressos e periódicos. Recentemente tem trabalhado na área de Cidades Inteligentes e gostaria de ter mais tempo para tocar seu vibrafone.

[FSF 2022]

"Software Livre significa software que **respeita a liberdade dos usuários e a comunidade**"

...

"acesso ao código-fonte é condição necessária para o software livre"

...

"usuários têm a liberdade de executar, copiar, distribuir, estudar, alterar e melhorar o software."

#### Ciência Aberta

[FOSTER 2022]

"Ciência Aberta é a prática científica que **permite a colaboração e contribuição de terceiros**"

---

"com disponibilização de dados, anotações, processos de pesquisa"

"sob condições que permitem o reuso, redistribuição e reprodução da pesquisa e seus dados e métodos subjacentes."

# O que é Software Livre?

## O que é software livre?

- Preço?
- Licença?
- Engenharia de software?
- Movimento social?
- Hobby?
- Luta contra a Microsoft?
- Realidade de mercado?

## O que é software livre?

- A Free Software Foundation define como:
  - Liberdade para executar o programa
  - Liberdade para estudar e modificar o programa
  - Liberdade para redistribuir o programa
  - Liberdade para melhorar e redistribuir as melhorias ao programa

- 1976 Bill Gates e sua "carta aberta aos hobbistas"
  - Software para microcomputadores tem grande potencial comercial
  - Não é possível financiar desenvolvimento fora do modelo de prateleira

- 1984 Richard Stallman lança o projeto GNU
  - uso de software restrito não é ético
- 1985 A Free Software Foundation é fundada por Richard Stallman
  - dedica-se a eliminação de restrições sobre a cópia, estudo e modificação de programas de computadores bandeiras do movimento do software livre, em essência

- 1991 É lançamento/surgimento do Linux
  - Linux refere-se aos sistemas operacionais que utilizam o Kernel Linux
  - O núcleo foi desenvolvido por Linus Torvalds, inspirado no sistema Minix, como projeto informal, apenas para estudo

- 1995 Boom da Internet
  - tem início a comercialização em escala do Linux, por exemplo, o Red Hat Linux.

- 1997 Eric Raymond apresenta "a Catedral e o Bazar"
  - vantagens técnicas do software livre
  - mecanismos de funcionamento do desenvolvimento descentralizado

- 1998 Netscape libera o código fonte do navegador Mozilla sob licença livre
- 1998 Eric Raymond, Linus Torvalds e outros lançam o movimento Open Source
  - software livre por razões técnicas
  - expressão open source ao invés de free software

- 1999 Sourceforge é lançado
- 2000 OpenOffice é lançado
- 2001 IBM investe US\$1bi no Linux

- Propriedade física x Propriedade intelectual
  - objetos ≠ ideias
- Desenvolvimento do conhecimento depende do compartilhamento de ideias
- Desenvolver novas ideias depende também de dinheiro

- A solução de compromisso dos direitos de autor procurava equilibrar o interesse privado e o interesse público
- Hoje em dia, mudanças na legislação e na tecnologia destruíram esse equilíbrio

- Quem decide?
  - dentro do nosso contexto social e cultural, só há uma resposta razoável: o autor
  - a escolha por parte do autor também é adequada do ponto de vista legal, já que ele é o detentor do direito de autor (ou copyright)

## Copyright

- para que alguém diferente do autor possa fazer praticamente qualquer tipo de uso desse trabalho, é preciso haver uma permissão explícita por parte do autor
- tipicamente, essa permissão é formalizada através de uma licença ou contrato escrito

- Copyright
  - essa licença ou contrato é um documento jurídico e, como tal, precisa ser razoavelmente detalhada e precisa
  - o autor é quem define os termos dessa licença ou contrato

## Copyright

Nas leis americanas, europeias e brasileiras, trata-se de direitos outorgados pelo estado e não de "direitos naturais"; tanto que passam para domínio público e têm restrições através do "fair use", diferentemente da propriedade física

- Software é um caso especial:
  - É um meio de produção, diferentemente de um livro
    - Ainda assim, é abstrato
  - Poucas "invenções" são de fato patenteáveis; além disso, a complexidade reduz grandemente a relevância de invenções isoladas

- Ainda assim, o software é tipicamente protegido por copyright (por 95 anos) e por patentes nos EUA (por 17 anos)
- Além disso, o código fonte é secreto
- O resultado é que há um desequilíbrio entre o interesse público e o privado

# Por que Software Livre?

- Surgimento da comunidade de software livre foi uma reação
  - retorno ao compartilhamento (do código-fonte)
     e à colaboração (troca de ideias e trabalho em equipe)
  - só é possível em um ambiente que facilite a troca de código-fonte (Internet)

- Opção ética
  - conhecimento público, disponível a toda sociedade
- Impacto na sociedade
  - conhecimento estratégico e fundamental demais para ficar nas mãos de apenas um grupo
- Metodologia tecnicamente interessante
  - vantagens metodológicas, técnicas e de mercado

- Incentivo à colaboração como forma de relacionamento humano e de produção
- É uma ótima plataforma para a educação tecnológica
- Acesso a tecnologia de ponta a baixo custo

- Simplifica o compartilhamento do software de forma legal
- Oferece um melhor equilíbrio entre o interesse privado e o interesse público em relação ao estado atual das leis de copyright

- Relação da população em geral com o software tende a se tornar cada vez mais próxima
- O compartilhamento do conhecimento é uma forma de inclusão digital

- Software Livre permite o compartilhamento de código, otimizando o uso dos recursos
  - Menos duplicação de esforço
  - Menor custo de desenvolvimento

- Oportunidade para melhoria da qualidade
  - Vários olhos enxergam mais
  - Orgulho pessoal incentiva desenvolvedor a ser mais cuidadoso
  - Vários usuários envolvidos promovem melhorias e relatórios de erros

- Não há restrição de fornecedor: mais interessante para o usuário
- Sempre é possível evoluir o código, mesmo que o fornecedor original abandone o mercado

# Licenças de Software Livre

## Origem das licenças de software livre

- Software não-livre é a norma
- Há leis rígidas sobre copyright
- Patentes de software (inválidas no Brasil, porém)
   que afetam o desenvolvimento
- Pessoas diferentes têm visões diferentes

## Licenças de Software Livre

- Os desenvolvedores de software livre evitam redigir "do zero" as licenças detalhando essas condições
- dá trabalho escrever uma licença consistente do ponto de vista jurídico

## Licenças de Software Livre

- não é necessário "reinventar a roda"
- se o objetivo é o compartilhamento do código, códigos diferentes com condições de uso e distribuição diferentes atrapalham

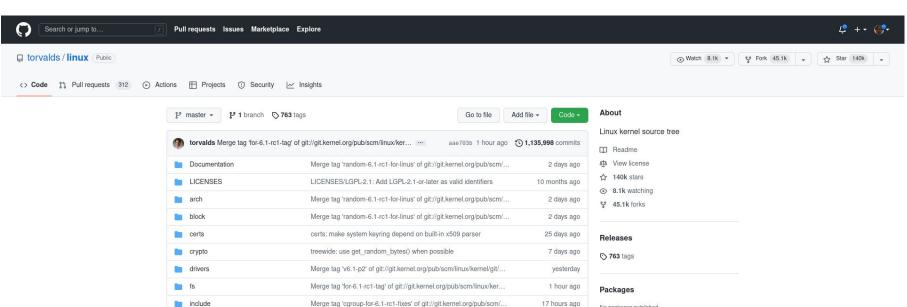
- Por isso, existem licenças comumente usadas por programadores com visões e interesses similares dependendo do contexto e do projeto
  - Ainda assim, existem mais de 70 licenças
     "reconhecidas" pela OSI (Open Source Initiative)

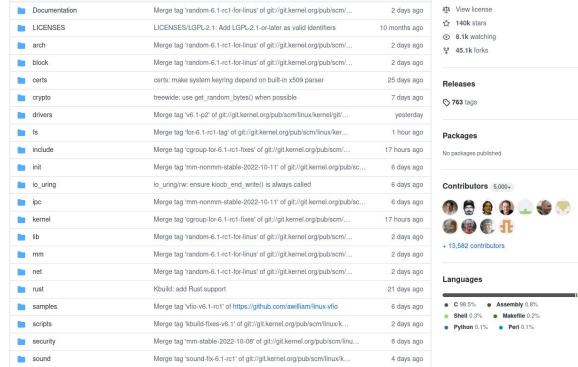
- Apesar desse grande número de licenças diferentes, pode-se agrupá-las em 3 categorias principais:
  - Recíprocas totais
  - Recíprocas parciais
  - Permissivas

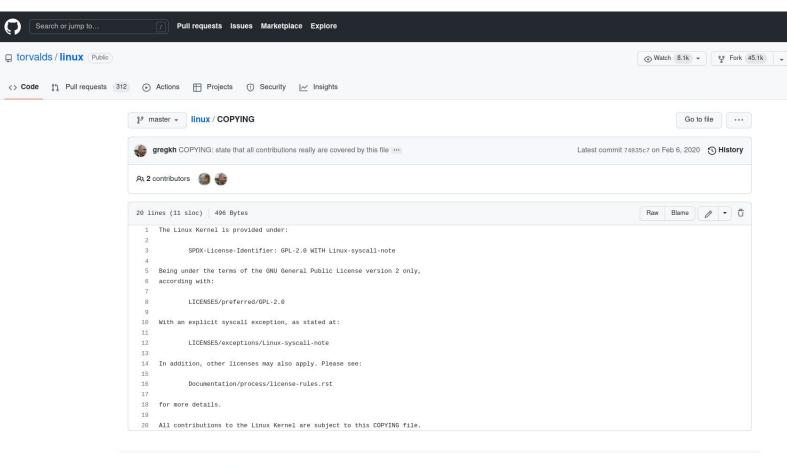
- Recíprocas totais
  - GPL, AGPL e similares
  - O software é livre, deve permanecer livre e trabalhos derivados devem ser também livres
    - Exigem que trabalhos relacionados ao trabalho original de alguma maneira sejam licenciados sob a mesma licença do trabalho original

- Recíprocas parciais
  - LGPL, EPL, MPL e outras
  - O software é livre e deve permanecer livre, mas trabalhos derivados não precisam ser livres
    - Permitem que projetos independentes que apenas utilizem as funcionalidades deste código sejam licenciados de forma independente

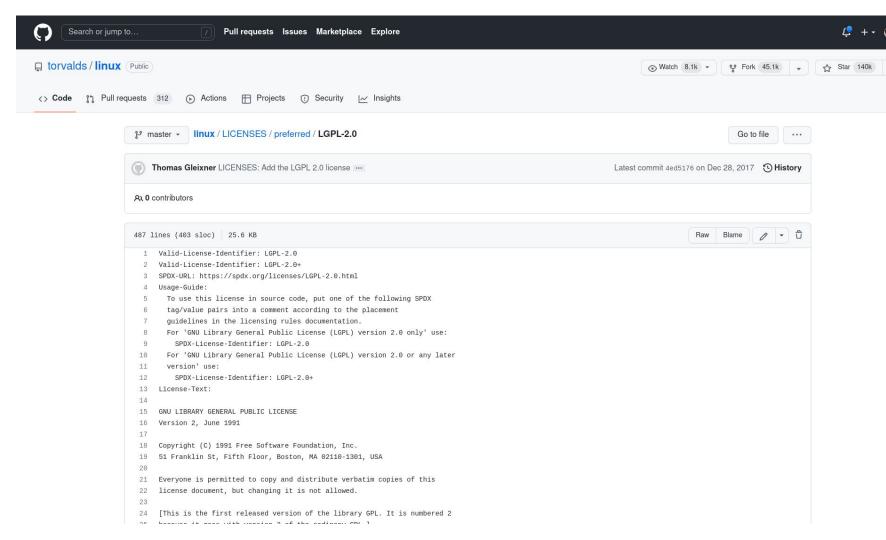
- Permissivas
  - Apache, MIT/X11, BSD e outras
  - O software é livre, mas pode ser relicenciado sem permissão adicional do autor
    - Interessantes quando o objetivo é disseminar o software e a tecnologia correspondente, independente da licença final
    - a implementação TCP/IP do BSD, que foi a primeira utilizada no linux mas também foi a utilizada no Windows



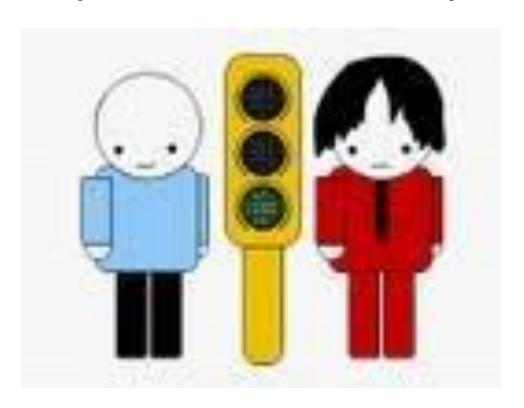




Star 140k



## (Creative Commons)

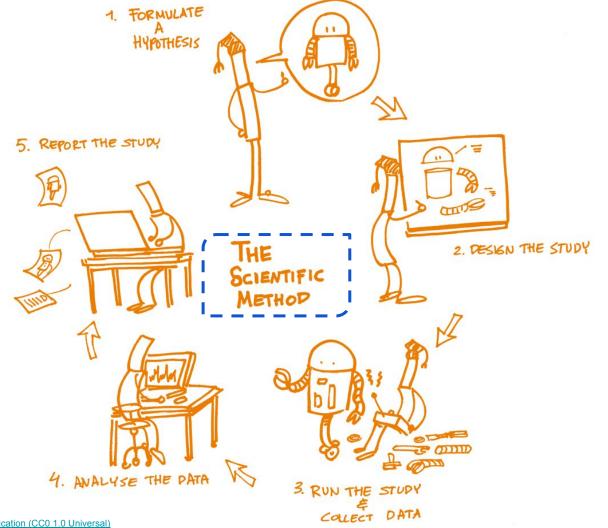


## O que é Ciência Aberta?



# Ciência

Método Científico

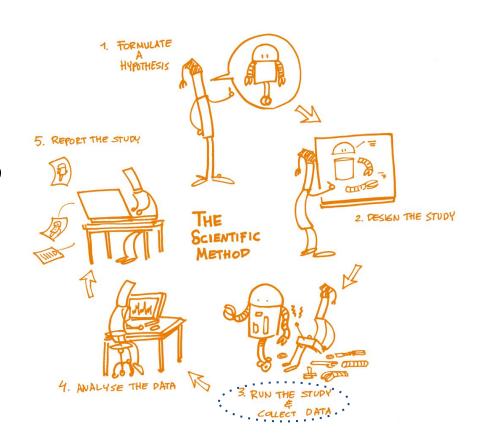


#### Ciência 1.0

- coleta de dados individual
- escrever artigo
- submeter artigo para revisão
- "gatekeepers" e revisão por pares
- publicar ou rejeitar



informação disponível para o público (ou não?)



#### Ciência 1.0

- coleta de dados individual
- escrever artigo
- submeter artigo para revisão
- "gatekeepers" e revisão por pares
- publicar ou rejeitar

informação disponível para o público (ou não?)

#### Ciência 2.0

- pré-registrar estudos
- compartilhar ideias, dados, métodos e protocolos, via blogs, plataformas, repositórios
- submeter preprints
- publicar em blogs, wikis, e journals



informação e dados disponíveis para o público

Recomendação da <u>UNESCO</u>:

Open Science is the movement to make scientific research and data accessible to all.

It includes practices such as publishing open scientific research, campaigning for open access and generally making it easier to publish and communicate scientific knowledge.

Recomendação da <u>UNESCO</u> (continuação)

"Additionally, it includes other ways to make Science more **transparent** and **accessible** during the research process.

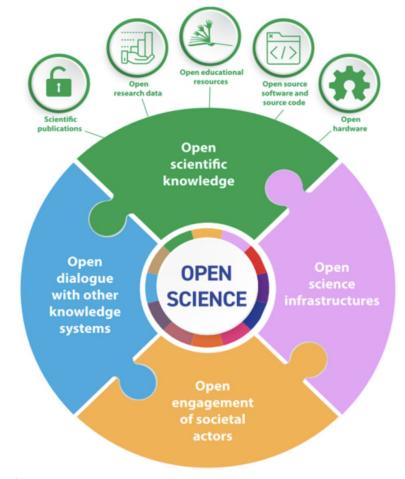
This includes [..] aspects of open source and crowdfunded research projects."

Definição da Comissão Europeia:

Open Science represents a new approach to the scientific process based on cooperative work and new ways of diffusing knowledge by using digital technologies and new collaborative tools.

#### Open\*

- open access (publications)
- open data
- open educational resources
- open source software
- open hardware



## Pesquisa Aberta e Reprodutível

## Reprodutibilidade é essencial

Um estudo é reproduzível se houver um conjunto específico de funções/análises computacionais (geralmente especificadas em termos de código) que reproduzam exatamente todos os resultados de um artigo publicado a partir de dados brutos.

## Pesquisa Aberta e Reprodutível

## Replicabilidade é mais "forte"

Um estudo só é replicável se alguém realizar exatamente o mesmo experimento (pelo menos) duas vezes, coletar dados da mesma maneira nas duas vezes, realizar a mesma análise de dados e chegar às mesmas conclusões.

## Pesquisa Aberta e Reprodutível

Se **reprodutibilidade** é uma característica relevante, **preservar** e **dar acesso** 

a código e workflows

torna-se vital para a credibilidade da pesquisa.

#### Software na Ciência Aberta

Bibliotecas, scripts, ferramentas, ...

- Limpeza de dados
- Processamento e visualização de dados,
- Criação de modelos
- Análise e predição, etc.

## Better Software, Better Research

"Devemos reconhecer o software como instrumento experimental de primeira-classe na Ciência."

**Carole GOBLE**. Better software, better research. IEEE Internet Computing, IEEE, v. 18, n. 5, p. 4–8, 2014.

"Existência de muitos projetos com poucos usuários, com ciclos de vida curtos que se encerram junto ao financiamento inicial, comunidades de usuários desconectadas e paralelas, incompatibilidades entre os projetos de maneira persistente e imutável, e tentativas constantes e aparentemente não coordenadas de "reiniciar" tudo (re-boots)."

**HOWISON, J. et al.** Understanding the scientific software ecosystem and its impact: Current and future measures. Research Evaluation, 2015.

"Poucos estudos são replicáveis: faltam informações incluindo dados e ferramentas, e apenas 20% dos estudos possuem ferramentas disponíveis.

**AMANN, S. et al.** Software mining studies: Goals, approaches, artifacts, and replicability. In: Software Engineering. [S.I.]: Springer, 2015. p. 121–158.

"... o atual modelo científico produz um 'tsunami' de ferramentas não-usáveis ... apenas metade delas são 'fáceis de instalar', e próximo de 1/3 não são mais instaláveis a partir da URL fornecida no artigo original ..."

**HERSHBERG, Elliot.** How Software in the Life Sciences Actually Works (And Doesn't Work). New Science, 2022: https://newscience.org/how-software-in-the-life-sciences-actually-works-and-doesnt-work.

## Boas práticas no desenvolvimento de Software Livre

- uso de repositórios públicos
- sistemas de controle de versão
- colaboração por pares
- revisão de código
- testes automatizados
- formatos e interfaces padrão
- documentação relevante

• ...

Boas práticas para a Ciência Aberta?

# Software Livre e Ciência Aberta

A liberdade para executar o software para qualquer finalidade:

 permite que pesquisadores utilizem o software existente sem ter que comprá-lo ou construí-lo do zero para realizar seus próprios estudos.

A liberdade para estudar e modificar o software na forma de código-fonte:

- oferece suporte à reprodutibilidade e replicabilidade, divulgando software de pesquisa, artefatos relacionados e o conhecimento embutido neles.
- aumenta a transparência (fluxos de trabalho visíveis),
   auditabilidade e confiabilidade (os resultados podem ser verificados por terceiros e qualquer pessoa pode detectar e corrigir um erro ou um recurso malicioso).

A liberdade para redistribuir cópias possibilita o compartilhamento de pacotes de **reprodução e replicação** com:

- a. dados brutos originais
- b. código necessário para realização dos experimentos, análises e interpretações em diferentes ambientes.

A liberdade para distribuir versões modificadas do software permite que pesquisadores

- desenvolvam seu próprio trabalho, reutilizando e expandindo o fluxo de trabalho, código-fonte ou ferramenta de terceiros
- compartilhem o novo conhecimento para o benefício de toda a comunidade científica.

#### Sistemas de Controle de versão

 Manutenção de várias versões do mesmo software, possivelmente, referenciadas por experimentos de pesquisa e artigos científicos.

## Repositórios Abertos

 Compartilhamento de vários tipos de ativos de pesquisa (algoritmos, dados, código, relatórios e fluxos de trabalho), apoiando a reprodutibilidade, reduzindo a redundância e promovendo a colaboração científica aberta.

## Colaboração entre Pares

 A colaboração entre pares é frequente e habilitada por meio de acesso compartilhado ao código-fonte e vários canais de comunicação.

## Revisão de Código

 A revisão de código promove a melhoria da qualidade do software por meio de compartilhamento, colaboração e revisão por pares e pode ser aplicada a outros ativos de pesquisa.

#### **Testes**

 Os testes automatizados aumentam a confiabilidade e a facilidade de manutenção, além de promover agilidade no desenvolvimento de novos recursos.

## **Padronização**

 O uso de formatos de dados e interfaces padronizados facilita a integração com outros sistemas e desencoraja a dependência de fornecedores específicos.

72

## Documentação

 A documentação frequente e contínua é uma prática recomendada para manter os guias do usuário, manuais e outros documentos relevantes atualizados em relação à versão mais recente do software.

# Boas práticas de Software Livre podem ser consideradas Boas práticas para a Ciência Aberta

#### Suporte contínuo à:

- disponibilidade e reúso de ativos
- colaboração entre pares
- transparência do fluxo de trabalho
- confiabilidade

## Software Acadêmico

(software desenvolvido ou utilizado no contexto da pesquisa científica)

## Research Software

## **FAIR 4 Software**

O software desenvolvido ou utilizado no contexto de uma pesquisa científica deve ser FAIR:

(F)indable: localizável

(A)ccessible: acessível

(I)nteroperable: interoperável

(R)eusable: reutilizável

## **Software Livre é FAIR**

#### **Findable**

Software livre pode ser localizado em repositórios com base em **identificadores e descritores**, utilizando diversos critérios como palavras-chave, linguagem de programação, versão do software, entre outros.

## **Software Livre é FAIR**

#### **Acessible**

A acessibilidade é encorajada em software livre disponível em **repositórios abertos**, com licenças de compartilhamento explícitas e bem definidas e documentação associada.

## **Software Livre é FAIR**

## Interoperable, Reusable

A definição de interfaces de programação e formatos de entrada/saída e o uso de padrões promovem a interoperabilidade e o reúso por vários grupos de pesquisa em todo o mundo.

# Software Livre é fundamental para a Ciência Aberta

Esta mensagem deve ser transmitida a cientistas, agências de fomento à pesquisa, organizações científicas e governamentais.

## Better Software, Better Research

"Devemos reconhecer o software como instrumento experimental de primeira-classe na Ciência."

#### **Paulo Meirelles**

@paulormm paulo.meirelles@ufabc.edu.br

Christina von Flach @chrisflach flach@ufba.br



## **COMPUTAÇÃO°**





#### CIÊNCIA ABERTA - COLABORAÇÃO SEM BARREIRAS PARA O AVANÇO DO CONHECIMENTO

ue é Ciència Aberta? amos separar a 'espeificação' da 'implemenação". Embora não haja ıma definição fixa para termo "Ciência Aberta", ele costuma ser usado para denotar o conjunto de políticas, iniciativas e ações e desenvolvimento em Computação.

Ciência Aberta - introdução e implemen- para disseminar e compartilhar conhecimento, geralmente por meio digital, para que todos os resultados associados à a todos. O conceito principal desta especificação é colaboração sem barreiras - geográficas, temporais, culturais, sócio-econômicas ou políticas.

A implementação exige pesquisa

COMPUTAÇÃO BRASIL I DEZEMBRO 2021 8



#### **SOFTWARE LIVRE: PRÉ-REQUISITO** PARA A CIÊNCIA ABERTA

Christina von Flach e Fabio Kon flach@ufba.br, kon@ime.usp.br

ciência sempre se pautou pela disseminação do conhecimento, com destague para a mentos. É claro que há limites práticos - e mesmo éticos - para o que pode ser compartilhado e reproduzido, mas expandir esses limites é um objetivo de interesse o foco do movimento pela ciência aberta, que tem tido bastante repercussão nos últimos anos.

A Ciência Aberta requer que as ferramentas e os instrumentos necessários para a prática científica estejam dis-

poníveis para todos, de modo que os experimentos possam ser reproduzidos e os resultados verificados por terceiros. No reprodutibilidade de experi- Século 21, o software consolidou-se como onipresente no conjunto de ferramentas usado por pesquisadores das Ciências Exatas e Biomédicas e tem uso crescente nas Ciências Sociais e Humanas. Software para cientistas de todas as áreas. Esse é é usado para limpeza, processamento e visualização de dados, bem como para criar modelos e realizar previsões. Algoritmos especializados são codificados na forma de bibliotecas, scripts e metadados. Sem compartilhar todos esses artefatos, é muito difícil e custoso reproduzir a pesquisa científica e validar sua correção.



# **Obrigado!**